

强化学习实验报告 (CartPole-v0, 策略梯度+Baseline、RTG、优势归一化对照实验)

光电2610 姜涵婷

摘要

本实验基于策略梯度 (Policy Gradient) 算法, 在CartPole-v0倒立摆环境下设计三组消融对照实验, 分别探究Baseline价值基线、Reward_to_go (RTG)、优势归一化对策略梯度训练效果的影响。实验提供完整代码框架, 网络结构、环境主循环、WandB日志、参数解析等基础代码已预置。本人完成全部标记TODO位置的核心算法逻辑实现, 经过多轮代码调试排查各类运行问题, 保障程序可以正常执行; 依托代码内置功能开关完成三组对照实验, 完成WandB指标导出、绘图、实验分析与报告撰写。

第一组对照: 关闭全部改进模块与仅开启Baseline对比;

第二组对照: 关闭全部改进模块与同时开启RTG+优势归一化对比;

第三组对照: RTG+优势归一化组合、Baseline+RTG+优势归一化完整模块组合对比。

所有实验组通过WandB记录平均回报、回报标准差、actor_loss、critic_loss等关键指标。实验验证: Baseline可以降低策略梯度估计方差; RTG结合优势归一化能够稳定梯度更新尺度; 三者共同启用可以进一步抑制训练震荡, 提升训练稳定性。

一、实验目的

1. 理解策略梯度算法原理, 掌握基于轨迹回报更新策略网络的实现方法。
2. 理解Baseline价值线、Reward_to_go、优势归一化的原理, 掌握优势函数 $A_t = G_t - V(s_t)$ 的物理含义, 区分Reward、Baseline、Loss三者之间的关系。
3. 通过多组消融对照实验, 分别验证Baseline、RTG、优势归一化各自以及组合对降低梯度方差、稳定训练的作用。
4. 熟悉强化学习完整实验流程: 实现算法核心片段、轨迹采样、网络参数更新、WandB可视化与多组对照实验结果分析。

二、本人完成的工作

本实验已提供完整项目代码框架, 网络类定义、环境交互主循环、WandB日志记录、命令行参数配置、训练调度逻辑均已预先编写完成。本人完成所有代码标记为TODO处的算法逻辑实现, 在编码完成后持续开展调试排错, 反复测试修正, 最终保证整套代码逻辑通顺、能够正常运行; 后续开展实验、数据分析与报告撰写, 具体工作如下:

1. 策略网络前向逻辑实现: 补全离散动作空间策略前向传播代码, 基于观测输出动作分布; 实现策略动作采样相关逻辑。
2. 轨迹采样交互逻辑实现: 完成轨迹采样循环内TODO片段, 实现依据当前观测采样动作、环境执行动作获取转移数据、回合终止条件判断, 完成单条轨迹数据采集。
3. 回报计算函数实现: 编写折扣总回报、Reward_to_go未来折扣回报两套计算函数, 实现蒙特卡洛Q值求解, 配合配置开关切换两种回报计算模式。
4. 优势估计逻辑实现: 完成优势函数计算, 实现无Baseline、Baseline优势估计分支; 实现批次内优势归一化, 对批次优势做标准化 (均值归零、方差为1)。

5. Actor损失与更新逻辑：完成策略梯度Actor损失计算，利用优势函数计算对数概率损失；实现优化器梯度清零、反向传播、策略网络参数更新流程。
6. Critic价值网络损失与更新：实现价值网络MSE损失计算，拟合状态价值作为Baseline；完成Critic网络梯度反向传播与参数迭代更新。
7. 多轮代码调试与验证：代码编写完毕后反复调试运行，排查并修复张量维度不匹配、数组运算、变量调用等报错问题，逐一验证use_baseline、use_reward_to_go、normalize_advantages各功能开关均可正常切换生效，确保整体程序可以稳定跑通训练流程。
8. 消融对照实验执行：遵循单一变量原则，固定其余超参数，仅切换功能开关，全部实验组统一设置n_iter=200，完成4组实验配置训练。
9. 数据处理与报告撰写：从 WandB导出各组训练指标，制作对照图表；分析实验曲线现象，完成报告撰写、图注标注与结果 归纳。

三、算法原理

3.1 无任何改进（原始PG）

策略梯度估计公式： $\nabla J \approx \sum_t G_t \nabla \log \pi(a_t | s_t)$

G_t 代表整条轨迹从0时刻开始的折扣总回报。该方案 直接将原始全轨迹回报作为梯度权重；轨迹回报本身波动较大，会带来较高的梯度估计噪声，训练过程震荡明显。

3.2 带Baseline

Critic网络拟合状态价值 $V(s_t)$ ，构造优势函数： $A_t = G_t - V(s_t)$

梯度更新： $\nabla J \approx \sum_t A_t \nabla \log \pi(a_t | s_t)$

Baseline不会改变梯度的数学期望，因此不会改变算法可达到的最优策略；它仅抵消状态固有回报偏移，实现降低梯度估计方差的效果。

Actor网络（策略网络）：输出动作概率分布，利用优势函数计算actor_loss，更新策略参数。

Critic网络（价值网络）：输入状态，输出预测状态价值 $V(s)$ ；仅开启Baseline时参与训练，损失采用 MSE均方误差。

3.3 Reward- to- Go(RTG)

原始PG使用整条轨迹总回报，把 t 时刻之后还未发生的回报也计入权重，引入额外噪声。RTG仅使用 t 时刻往后未来部分的折扣回报： $G_t - RTG = \sum_{t'=t}^T \gamma^{t'-t} r_{t'}$

消除过去时刻奖励带来的干扰，降低梯度估计偏差。

3.4 优势归一化

在单次迭代收集的全部样本上，对优势做标准化： $\tilde{A} = (A - \text{mean}(A)) / \text{std}(A)$

优势归一化不会改变优势本身的相对大小，只缩放尺度，避免回报量级差异造成梯度更新步长过大或者过小，稳定 梯度更新。

四、实验参数设置

参数	配置1 全部关闭(原始PG)	配置2 仅开启baseline
环境	CartPole-v0	CartPole-v0
use_baseline	False	True
use_reward_to_go	False	False
normalize_advantages	False	False
n_iter	200	200
learning_rate	0.005	0.005
baseline_learning_rate	0.005	0.005
n_layers	2	2
layer_size	64	64
discount	1	1
batch_size	1000	1000
eval_batch_size	400	400
seed	1	1
可视化工具	WandB	WandB

参数	配置3 RTG+归一化(关闭baseline)	配置4 baseline+RTG+归一化
环境	CartPole-v0	CartPole-v0
use_baseline	False	True
use_reward_to_go	True	True
normalize_advantages	True	True
n_iter	200	200
learning_rate	0.005	0.005
baseline_learning_rate	0.005	0.005
n_layers	2	2
layer_size	64	64
discount	1	1
batch_size	1000	1000
eval_batch_size	400	400
seed	1	1
可视化工具	WandB	WandB

对照分组说明：


1. 第一组对照：配置1 VS 配置2：全部关闭 vs 仅开启baseline，验证Baseline单独作用。
2. 第二组对照：配置1 VS 配置3：全部关闭 vs RTG+优势归一化，验证RTG与归一化组合带来的效果。
3. 第三组对照：配置3 VS 配置4：RTG+归一化 vs baseline+RTG+归一化，验证在RTG、归一化已经开启的基础上，Baseline带来的额外增益。

说明：每组对照严格保证除待验证开关之外其余超参数保持一致，满足单一变量原则。CartPole-v0单条轨迹最大回报为200。

五、实验结果与图表分析

第一组对照：全部关闭(原始PG) VS 仅开启Baseline


图1 Train_AverageReturn（训练平均回报）对比曲线



图例：蓝色曲线=开启Baseline；紫色曲线=无Baseline。横轴：训练迭代Step(最大200)；纵轴：每轮迭代轨迹平均回报，上限200。回报越高，倒立摆维持直立时间越长，策略性能越好。

分析：两组最终均可以收敛至满分200，证明Baseline不会改变算法理论性能上限。原始PG(紫色)回报震荡幅度大，在step50-100区间发生明显性能回落，训练过程存在多次性能崩溃；开启Baseline(蓝色)后回报整体上升趋势更加平滑，性能断崖式下跌现象明显减少。Baseline通过减去状态固有价值偏移，降低梯度估计方差，让策略更新更加稳定。

图2 actor_loss对比曲线




图例：蓝色曲线=开启Baseline；紫色曲线=无Baseline。横轴：训练迭代Step(最大200)；纵轴：actor_loss(策略梯度损失)。actor_loss不能直接评判策略优劣，仅表征本轮策略更新幅度。

分析：原始PG组actor_loss整体数值高，曲线剧烈抖动，反映原始全轨迹回报作为梯度权重时，梯度噪声大，每一轮策略更新幅度波动剧烈。开启Baseline之后，actor_loss整体幅值下降，震荡幅度显著减小。优势函数($G_t - V(s_t)$)过滤掉状态固有回报带来的噪声，梯度估计更加稳定，每一轮


参数更新的变化幅度变得平缓。需要注意：actor_loss的大小不等价于策略好坏，仅反映策略更新的步长。

图3 Train_StdReturn（回报标准差）对比曲线



图例：蓝色曲线=开启Baseline；紫色曲线=无Baseline。横轴：训练迭代Step(最大200)；纵轴：同一迭代批次内多条轨迹回报标准差。标准差越大，代表轨迹回报差异越大，采样结果越不稳定。
分析：对照组StdReturn整体水平偏高，不同轨迹回报差距大；实验组StdReturn明显更低。实验现象证明Baseline能够有效降低采样回报波动，减少梯度估计噪声，与理论分析结论保持一致。


图4 critic_loss曲线（仅Baseline实验组）



横轴：训练迭代Step(最大200)；纵轴：Critic网络MSE损失，表征状态价值预测值与真实回报之间的拟合误差。
分析：训练初期critic_loss数值很高，Critic网络尚未学到准确的状态价值；随着迭代增加，MSE损失逐步下降并趋于收敛。Critic Loss的收敛代表网络对状态价值 $V(s)$ 的拟合精度不断提升，Baseline的降噪效果也随之增强。Critic拟合误差会直接影响优势函数的计算质量，若Critic无法收敛，Baseline降方差的效果会被削弱。

第二组对照：全部关闭(原始PG) VS RTG+优势归一化（关闭Baseline）


图5 Train_AverageReturn对比曲线（原始PG VS RTG+优势归一化）



图注：开启RTG+归一化的actor_loss对比原始策略梯度（全部模块关闭）与同时开启Reward_to_go、优势归一化的训练平均回报。横轴：训练迭代Step(最大200)，纵轴：训练平均回报。（紫线=原始PG，绿线=开启RTG+归一化的对照组）

分析：原始PG回报曲线剧烈震荡，训练中多次出现回报大幅度跌落，收敛速度慢。开启RTG+优势归一化之后，收敛速度明显加快，回报整体维持在更高水平，震荡幅度显著降低。RTG抛弃t时刻之前无关的历史回报，减少梯度估计偏差；优势归一化统一优势的尺度，避免回报量级差异造成更新异常。二者共同作用，在不使用Baseline的条件下也可以有效改善训练稳定性。


图6 Train_StdReturn对比曲线（原始PG VS RTG+优势归一化）




图注：回报标准差对比，横轴迭代Step(最大200)，纵轴批次轨迹回报标准差。（紫线=原始PG，绿线=开启RTG+归一化的对照组）

分析：RTG+归一化实验组回报标准差整体低于原始PG，代表批次内轨迹之间性能差异减小，采样梯度噪声得到抑制。

图6 actor_loss



图注：actor_loss对比曲线。横轴迭代Step(最大200)，纵轴actor_loss。紫线=原始PG，绿线=开启RTG+归一化的对照组




图注：开启RTG+归一化的actor_loss

分析：原始PG的actor_loss峰值高、抖动剧烈；开启RTG+归一化后actor_loss整体幅值大大下降，曲线抖动明显减弱。RTG降低回报估计的偏差，优势归一化将优势缩放至统一尺度，使得每一轮梯度的量级更加稳定，策略网络更新更加平稳。

第三组对照：RTG+优势归一化 VS baseline+RTG+归一化


图7 Train_AverageReturn对比曲线（RTG+归一化 VS Baseline+RTG+归一化）



图注：两组均开启RTG与优势归一化，变量仅为是否开启Baseline。横轴迭代Step(最大200)，纵轴训练平均回报。（绿线=无baseline 橙线=开启baseline）

分析：两组均可以收敛至CartPole满分200。仅RTG+归一化的实验组虽然已经有不错的稳定性，但训练过程依旧存在少量小幅的回报波动；叠加Baseline之后，回报曲线进一步平滑，几乎没有出现断崖式性能下跌。说明在RTG、优势归一化已经生效的基础上，Baseline依旧可以进一步降低梯度方差，带来额外的稳定性增益，多个改进存在协同效应。


图8 Train_StdReturn对比曲线（RTG+归一化 VS Baseline+RTG+归一化）



图注：回报标准差对比。横轴迭代Step(最大200)。（绿线=无baseline 橙线=开启baseline）


分析：开启Baseline后，回报标准差进一步降低，证明Baseline、RTG、优势归一化三者之间存在协同效果。

图8 actor_loss对比曲线（RTG+归一化 VS Baseline+RTG+归一化）



图注：actor_loss对比曲线。横轴迭代Step(最大200)，纵轴actor_loss。（绿线=无baseline 橙线=开启baseline）
分析：两组actor_loss均处在较低区间；开启Baseline的实验组actor_loss波动幅度更小。RTG与归一化已经完成偏差修正与尺度归一，Baseline进一步过滤状态相关噪声，梯度估计的方差被进一步压缩，策略网络每一轮更新更加温和稳定。

图9 critic_loss曲线（完整配置baseline+RTG+归一化）



图注：完整模块配置下Critic网络MSE损失变化曲线。横轴迭代Step(最大200)。（蓝线=无RGT+归一化）

分析：critic_loss前期较高，随着迭代逐步下降收敛。在RTG+归一化的条件下，Critic依然可以正常拟合状态价值。对比仅Baseline实验组，整体收敛趋势相近，说明RTG、归一化不会干扰Critic网络的训练。critic_loss收敛，代表优势函数的计算可靠，Baseline可以充分发挥降噪作用。

六、实验讨论

1. Baseline本质：不修改环境原始Reward，不改变最优策略；仅修改梯度更新权重，实现降低梯度估计方差、稳定训练的目的，但需要额外训练Critic网络，带来一定计算开销。
2. Reward_to_go：舍弃t时刻之前的历史回报，减少梯度估计偏差；优势归一化缩放优势的量级，稳定梯度更新步长，二者组合即使不使用Baseline，也可以显著改善原始PG震荡严重的问题。

3. RTG、优势归一化、Baseline三者效果可以叠加：RTG降低偏差；Baseline降低梯度方差；优势归一化稳定梯度尺度；全部开启时训练稳定性达到最优。
4. 指标区分：Return是策略性能指标；actor_loss代表策略更新目标，只反映更新幅度，不能单独判断策略好坏；critic_loss代表价值网络拟合精度；三者物理意义不同，不可混淆。
5. 实验局限：本次实验仅使用CartPole简单离散环境；全部实验n_iter统一为200，仅使用单一随机种子seed=1，结果会存在少量随机偶然性；没有测试GAE等更加高级的优势估计方案。

七、实验结论

本实验使用提供的基础代码框架，本人完成代码所有TODO标记位置的策略梯度核心算法逻辑实现，经过多轮调试排错保障代码正常运行，设置所有实验组统一迭代次数 n_iter=200，完成三组消融对照实验的设计、调试、训练、WandB指标采集与结果分析。

在CartPole-v0倒立摆任务中，保持绝大多数超参数不变开展多组对照。实验结果表明：

1. Baseline借助Critic网络估计状态价值，构造优势函数更新策略，不改变最优回报上限，但是可以降低梯度估计方差，减弱训练震荡，actor_loss震荡程度同步降低。
2. RTG折扣未来回报结合优势归一化，能够改善原始PG训练不稳定问题，加快收敛，降低回报波动，同时抑制Actor Loss的剧烈抖动。
3. 将Baseline、RTG、优势归一化全部开启，三者协同作用，可以获得最为平滑稳定的训练曲线。

配图清单

1. 图1: Train_AverageReturn对比(原始PG VS 仅Baseline)
2. 图2: actor_loss对比(原始PG VS仅Baseline)
3. 图3: Train_StdReturn对比(原始PG VS 仅Baseline)
4. 图4: critic_loss曲线(仅Baseline实验组)
5. 图5: Train_AverageReturn对比(原始PG VS RTG+归一化)
6. 图6: Train_StdReturn对比(原始PG VS RTG+归一化)
7. 图6-1: actor_loss对比(原始PG VS RTG+归一化)
8. 图7: Train_AverageReturn对比(RTG+归一化 VS Baseline+RTG+归一化)
9. 图8: Train_StdReturn对比(RTG+归一化 VS Baseline+RTG+归一化)
10. 图8-1: actor_loss对比(RTG+归一化 VS Baseline+RTG+归一化)
11. 图9: critic_loss曲线(Baseline+RTG+归一化) + critic_loss曲线对比(仅Baseline VS Baseline+RTG+归一化)